

Report

First step is to create the tables on the dataset.

```
37 FOREIGN KEY (id_client) REFERENCES clients(id_client) ON DELETE CASCADE,
38 INDEX idx_client (id_client),
39 INDEX idx_date (date_commande)
40 ) ENGINE=InnoDB;
41
42 -- =====
43 -- TABLE : lignes_commandes
44 -- =====
45 CREATE TABLE lignes_commandes (
46   id_ligne INT AUTO_INCREMENT PRIMARY KEY,
47   id_commande INT NOT NULL,
48   id_produit INT NOT NULL,
49   quantite INT NOT NULL,
50   prix_unitaire DECIMAL(10,2) NOT NULL,
51   FOREIGN KEY (id_commande) REFERENCES commandes(id_commande) ON DELETE CASCADE,
52   FOREIGN KEY (id_produit) REFERENCES produits(id_produit) ON DELETE CASCADE,
53   INDEX idx_commande (id_commande),
54   INDEX idx_produit (id_produit)
55 ) ENGINE=InnoDB;
```

Automati
disabled. I
manually
current ca
toggle a

Context Help S

Output

#	Time	Action	Message
1	09:22:17	show tables	Error Code: 1046. No database selected Select the default DB to be used by double-clicking its name in the SCH
2	09:22:52	CREATE DATABASE ventes_oltp CHARACTER SET utf8mb4 COLLATE utf8mb4_unicode_ci	1 row(s) affected
3	09:22:52	USE ventes_oltp	0 row(s) affected
4	09:22:52	CREATE TABLE clients (id_client INT AUTO_INCREMENT PRIMARY KEY, nom VARCHAR(100) NOT NULL...	0 row(s) affected
5	09:22:52	CREATE TABLE produits (id_produit INT AUTO_INCREMENT PRIMARY KEY, nom_produit VARCHAR(200) ...	0 row(s) affected
6	09:22:52	CREATE TABLE commandes (id_commande INT AUTO_INCREMENT PRIMARY KEY, id_client INT NOT N...	0 row(s) affected
7	09:22:53	CREATE TABLE lignes_commandes (id_ligne INT AUTO_INCREMENT PRIMARY KEY, id_commande INT N...	0 row(s) affected

After creation we proceed to verify the tables in the dataset.

Field	Type	Null	Key	Default	Extra
id_client	int	NO	PRI	NULL	auto_increment
nom	varchar(100)	NO		NULL	
prenom	varchar(100)	NO		NULL	
email	varchar(150)	NO	UNI	NULL	
ville	varchar(100)	NO	MUL	NULL	

For clients.

Field	Type	Null	Key	Default	Extra
id_produit	int	NO	PRI	NULL	auto_increment
nom_produit	varchar(200)	NO		NULL	
categorie	varchar(100)	NO	MUL	NULL	
prix_unitaire	decimal(10,2)	NO		NULL	

For products.

Result Grid						
	Field	Type	Null	Key	Default	Extra
▶	id_commande	int	NO	PRI	NULL	auto_increment
	id_client	int	NO	MUL	NULL	
	date_commande	date	NO	MUL	NULL	
	montant_total	decimal(10,2)	NO		NULL	

For orders.

Result Grid						
	Field	Type	Null	Key	Default	Extra
▶	id_ligne	int	NO	PRI	NULL	auto_increment
	id_commande	int	NO	MUL	NULL	
	id_produit	int	NO	MUL	NULL	
	quantite	int	NO		NULL	
	prix_unitaire	decimal(10,2)	NO		NULL	

Result 9 ×

Output

For order lines.

Next step is to generate the dataset following this database structure using a library called faker in python.

To install it: `pip install faker`

The screenshot shows a PyCharm IDE with a project named 'Faker_generate'. The left sidebar displays a file explorer with the following files: 'clients.csv', 'commandes.csv', 'generate_code_tp3_amamou.py', 'lignes_commandes.csv', and 'produits.csv'. The main editor window shows the Python script 'generate_code_tp3_amamou.py' with the following code:

```
26 'prenom': fake.first_name(),
27 'email': f"{client(i)}@{fake.free_email_domain()}",
28 'ville': random.choice(villes),
29 'date_inscription': fake.date_between(start_date='-3y', end_date='today')
30 })
31
32 clients = pd.DataFrame(clients_data)
33 clients.to_csv(path_or_buf=f"C:/Users/fftt7/PycharmProjects/Faker_generate/clients.csv", index=False, encoding='utf-8')
34 nt(f"Fichier clients.csv créé : {len(df_clients)} lignes")
35
36 =====
37 ÉNÉRATION DES PRODUITS (500)
38 =====
39 nt("Génération de 500 produits...")
40
41 egories = {
42 'Ordinateurs': ['MacBook Pro', 'Dell XPS', 'HP Pavilion', 'Lenovo ThinkPad', 'Asus VivoBook'],
43 'Téléphones': ['iPhone 14', 'Samsung Galaxy S23', 'Google Pixel 7', 'OnePlus 11', 'Xiaomi 13'],
44 'Tablettes': ['iPad Pro', 'Samsung Galaxy Tab', 'Microsoft Surface', 'Lenovo Tab', 'Huawei MatePad'].
```

The bottom panel shows the 'Run' output for 'generate_code_tp3_amamou.py':

```
Génération de 20 000 commandes...
Génération de 100 000 lignes de commandes...
Fichier lignes_commandes.csv créé : 100000 lignes
Fichier commandes.csv créé : 20000 lignes
Génération terminée avec succès !
Fichiers créés : clients.csv, produits.csv, commandes.csv, lignes_commandes.csv
Process finished with exit code 0
```

The important thing to do is to change the path of the created file to the path you want to save the file in to get an easy access to them.

And as you can see 4 files are generated with the name of each SQL table.

In the next move, we need to import our csv into MySQL server.


Steps to load a dataset in SQL:

1. Clic droit sur la table **clients** → **Table Data Import Wizard**
2. Cliquez sur **Browse** et sélectionnez le fichier **clients.csv**
3. Cliquez sur **Next**
4. Sélectionnez **Use existing table : ventes_oltp.clients**
5. Cliquez sur **Next**
6. Vérifiez que les colonnes correspondent correctement (MySQL Workbench fait généralement la correspondance automatiquement)
7. Cliquez sur **Next** puis **Next** à nouveau

8. Attendez la fin de l'importation (quelques secondes pour 10 000 lignes)

9. Cliquez sur **Finish**

And you just wait some time in order your data loads bigger is your data the least pc in performance more time to load just wait.



Or you can use a code upload it is the fastest way :

-- Importer clients

LOAD DATA LOCAL INFILE

'C:/Users/fftt7/PycharmProjects/Faker_generate/clients.csv'

INTO TABLE clients

FIELDS TERMINATED BY ','

ENCLOSED BY ''''

LINES TERMINATED BY '\n'

IGNORE 1 ROWS


(id_client, nom, prenom, email, ville, date_inscription);

#	Time	Action	Message	Duration / Fetch
3	10:36:56	LOAD DATA LOCAL INFILE 'C:/Users/ftt7/PycharmProjects/Faker_generate/clients.csv' INTO TABLE clients F...		0.406 sec
4	10:37:16	SELECT * FROM ventes_otp.clients LIMIT 0, 1000	1000 row(s) returned	0.000 sec / 0.000 sec
5	10:37:50	select count(*) from ventes_otp.clients LIMIT 0, 1000	1 row(s) returned	0.000 sec / 0.000 sec
6	10:39:11	LOAD DATA LOCAL INFILE 'C:/Users/ftt7/PycharmProjects/Faker_generate/produits.csv' INTO TABLE produit...	500 row(s) affected Records: 500 Deleted: 0 Skipped: 0 Warnings: 0	0.031 sec
7	10:39:49	select count(*) from ventes_otp.produits LIMIT 0, 1000	1 row(s) returned	0.000 sec / 0.000 sec
8	10:40:04	LOAD DATA LOCAL INFILE 'C:/Users/ftt7/PycharmProjects/Faker_generate/commandes.csv' INTO TABLE co...	20000 row(s) affected Records: 20000 Deleted: 0 Skipped: 0 Warnings: 0	0.344 sec
9	10:40:19	select count(*) from ventes_otp.commandes LIMIT 0, 1000	1 row(s) returned	0.000 sec / 0.000 sec


We move to the other step is creating the star shape in the data warehouse in MySQL.

17	10:44:38	CREATE DATABASE ventes_dwh CHARACTER SET utf8mb4 COLLATE utf8mb4_unicode_ci	1 row(s) affected	0.015 sec
18	10:44:38	USE ventes_dwh	0 row(s) affected	0.000 sec
19	10:44:38	CREATE TABLE DimClient (id_client_dim INT AUTO_INCREMENT PRIMARY KEY, id_client_source INT ...	0 row(s) affected	0.032 sec
20	10:44:38	CREATE TABLE DimProduit (id_produit_dim INT AUTO_INCREMENT PRIMARY KEY, id_produit_source I...	0 row(s) affected	0.047 sec
21	10:44:38	CREATE TABLE DimDate (id_date_dim INT PRIMARY KEY, date_complete DATE NOT NULL UNIQUE, ...	0 row(s) affected	0.046 sec
22	10:44:38	CREATE TABLE FactVentes (id_vente INT AUTO_INCREMENT PRIMARY KEY, id_client_dim INT NOT ...	0 row(s) affected	0.047 sec


This is the creation of tables and it is validated.



Next step is to go to Pentaho in order to extract transform and load. We connect to the database in Sql.



These are the parameters of the connection.



In the next steps we will create the transformations needed to make the star shape in our database using the old database we have so we start by creating the client product date and gather them in the center table which will be used after for the analysis and the decision making graphs.

TP : Pipeline OLTP → ETL Pentaho

Connection : OLTP_MySQL

SQL :

```
SELECT
  id_client,
  CONCAT(prenom, ' ', nom) AS nom_complet,
  email,
  ville
FROM clients
```

Examine preview data

Rows of step: Table input (1000 rows)

#	id_client	nom_complet	email	ville
1	FrÃ©dÃ©ric Riou	client1@voila.fr	client1@voila.fr	Rennes
2	Maurice Moulin	client2@laposte.net	client2@laposte.net	Lyon
3	Nicole LabbÃ©	client3@hotmail.fr	client3@hotmail.fr	Paris
4	Arthur Briand	client4@voila.fr	client4@voila.fr	Reims
5	Nicolas Carpentier	client5@wanadoo.fr	client5@wanadoo.fr	Nice
6	Gabrielle Michel	client6@sfr.fr	client6@sfr.fr	Toulouse
7	Ã‰milie Boutin	client7@noos.fr	client7@noos.fr	Toulouse
8	Jacqueline Pons	client8@bouygnet.fr	client8@bouygnet.fr	Marseille
9	Susan Thierry	client9@free.fr	client9@free.fr	Reims
10	Zacharie Briand	client10@bouygnet.fr	client10@bouygnet.fr	Lyon
11	Paulette Fabre	client11@dbmail.com	client11@dbmail.com	Rennes
12	Alex Morin	client12@yahoo.fr	client12@yahoo.fr	Reims
13	Josette Barre	client13@bouygnet.fr	client13@bouygnet.fr	Bordeaux
14	CÃ©line Chauveau	client14@yahoo.fr	client14@yahoo.fr	Lyon
15	FranÃ©oise Chevalier	client15@club-internet.fr	client15@club-internet.fr	Lille
16	AgnÃ©s Maurice	client16@sfr.fr	client16@sfr.fr	Strasbourg
17	Benjamin Muller	client17@orange.fr	client17@orange.fr	Paris
18	Dominique Chevalier	client18@orange.fr	client18@orange.fr	Paris
19	Romain Gillot	client19@orange.fr	client19@orange.fr	Paris
20	Romain Gillot	client20@orange.fr	client20@orange.fr	Paris

2.3 - Ajouter un step

- Dans le panneau de gauche, sous Transform, trouvez **Select values**
- Glissez-dÃ©posez **Select values** sur le canvas
- CrÃ©ez un lien (hop) : maintenez Shift, cliquez sur "Lecture_Clients_OLTP", puis cliquez sur "Select values"
- Double-cliquez sur "Select values"
- RÃ©plissez :
 - Step name :** Renommer_Colonnes
 - Dans l'onglet **Select & Alter**, cliquez sur **Get fields to select**
 - Renommez les champs :
 - id_client → id_client_source
 - nom_complet → nom_complet (garder tel quel)
 - email → email (garder tel quel)
 - ville → ville (garder tel quel)
- Cliquez sur **OK**

2.4 - Ajouter un step "Table Output" (Chargement)

2.3 - Ajouter un step "Select values" (Transformation)

1. Dans le panneau de gauche, sous Transform, trouvez **Select values**

2. Glissez-dÃ©posez **Select values** sur le canvas

3. CrÃ©ez un lien (hop) : maintenez Shift, cliquez sur "Lecture_Clients_OLTP", puis cliquez sur "Select values"

4. Double-cliquez sur "Select values"

5. RÃ©plissez :

- Step name :** Renommer_Colonnes
- Dans l'onglet **Select & Alter**, cliquez sur **Get fields to select**
- Renommez les champs :
 - id_client → id_client_source
 - nom_complet → nom_complet (garder tel quel)
 - email → email (garder tel quel)
 - ville → ville (garder tel quel)

6. Cliquez sur **OK**

2.4 - Ajouter un step "Table Output" (Chargement)

1. Dans le panneau de gauche, sous Output, trouvez **Table output**

2. Glissez-dÃ©posez **Table output** sur le canvas

3. CrÃ©ez un lien (hop) : maintenez Shift, cliquez sur "Lecture_Clients_OLTP", puis cliquez sur "Table output"

4. Double-cliquez sur "Table output"

5. RÃ©plissez :

- Step name :** Charger
- Cliquez sur **Get fields to select**
- Cochez les champs : id_client_source, nom_complet, email, ville
- Cliquez sur **OK**

TP : Pipeline OLTP → ETL Pentaho

6. Cliquez sur OK

2.4 - Ajouter un step "Table Output" (Chargement)

1. Dans le panneau de gauche, sous **Output**, trouvez
2. Glissez-déposez **Table output** sur le canvas
3. Créez un lien depuis "Renommer_Colonne" vers "
4. Double-cliquez sur "Table output"
5. Remplissez :
 - Step name : **Ecriture_DimClient**
 - Connection : **DWH_MySQL**
 - Target schema : (laissez vide)
 - Target table : **DimClient**
 - Cochez **Truncate table** (pour vider la table avant)
 - Décochez **Specify database fields** (Pentaho se charge automatiquement)
6. Cliquez sur OK

Votre transformation doit ressembler à ceci : [Lecture_Clients_OLTP] → [Renommer_Colonne] → [Ecriture_DimClient]

13°C Eclaircies

Rechercher

11:15 21/11/2025

TP : Pipeline OLTP → ETL Pentaho

Votre transformation doit ressembler à ceci : [Lecture_Clients_OLTP] → [Renommer_Colonne] → [Ecriture_DimClient]

2.5 - Exécuter la transformation

1. Cliquez sur le bouton **Run** (icône "Play" verte) dans la barre d'outils
2. Dans la fenêtre qui s'ouvre, cliquez sur **Launch**
3. Observez l'exécution dans le panneau du bas
4. Vous devriez voir : "Lecture_Clients_OLTP : 10000 rows", "Ecriture_DimClient : 10000 rows"

Résultat attendu : La table DimClient contient maintenant 10 000 lignes. Vérifiez dans MySQL Workbench avec : `SELECT COUNT(*) FROM ventes_dwh.DimClient;`

Étape 3 : Transformation 2 - Charger DimProduit

Nous allons créer une transformation similaire pour les produits.

3.1 - Créer une nouvelle transformation

1. Cliquez sur **File → New → Transformation**

Execution Results

2025-11-21 11:12:49.667 - Carte - Installing timer to purge stale objects after 1440 minutes.

2025-11-21 11:15:54.594 - Spoon - Transformation opened.

2025-11-21 11:15:54.595 - Spoon - Launching transformation [dim_client]...

2025-11-21 11:15:54.596 - Spoon - Started the transformation execution.

2025-11-21 11:15:54.824 - dim_client - Dispatching started for transformation [dim_client]

2025-11-21 11:15:54.831 - Ecriture_DimClient.0 - Connected to database [DWH_MySQL] (commit=1000)



2025-11-21 11:15:54.910 - Table input.0 - Finished reading query, closing connection

2025-11-21 11:15:54.912 - Table input.0 - Finished processing (I=10000, O=0, R=0, W=10000, U=0, E=0)

2025-11-21 11:15:54.930 - Renommer_Colonne.0 - Finished processing (I=0, O=0, R=10000, W=10000, U=0, E=0)

2025-11-21 11:15:56.486 - Ecriture_DimClient.0 - Finished processing (I=0, O=10000, R=10000, W=10000, U=0, E=0)

2025-11-21 11:15:56.489 - Spoon - The transformation has finished!



TP : Pipeline OLTP → ETL Pentaho

3.4 - Ajouter un step "Table Output"

- Ajoutez **Table output** et créez le lien
- Configuration :
 - Step name : **Ecriture_DimProduit**
 - Connection : **DWH_MySQL**
 - Target table : **DimProduit**
 - Cochez **Truncate table**

3.5 - Exécuter la transformation

Cliquez sur **Run** et vérifiez que 500 produits sont chargés dans DimProduit

Résultat attendu : La table DimProduit contient 500 lignes

Étape 4 : Transformation 3 - Générer DimDate

La dimension date est particulière : elle n'existe pas dans l'OLTP. Nous allons la générer artificiellement pour couvrir la période 2022-2024.

4.1 - Créer une nouvelle transformation

Créez une nouvelle transformation et sauvegardez-la : **dim_date.ktr**

Spoon - dim_produit

table output

Input

Output

Streaming

Transform

Utility

Flow

Scripting

Pentaho Server

Lookup

Joins

Data Warehouse

Validation

Statistics

Big Data

Cryptography

Job

Mapping

Bulk loading

Inline

Experimental

Legacy

Deprecated

History

Execution Results

Logging

Execution History

Step Metrics

Performance Graph

Metrics

2025-11-21 11:17:34.766 - Spoon - Save file as...

2025-11-21 11:22:57.903 - Spoon - Transformation opened.

2025-11-21 11:22:57.903 - Spoon - Launching transformation [dim_produit]...

2025-11-21 11:22:57.903 - Spoon - Started the transformation execution.

2025-11-21 11:22:58.087 - dim_produit - Dispatching started for transformation [dim_produit]

2025-11-21 11:22:58.090 - Ecriture_DimProduit.0 - Connected to database [DWH_MySQL] (com

2025-11-21 11:22:58.103 - Lecture_Produts_OLTP.0 - Finished reading query, closing connector

2025-11-21 11:22:58.105 - Lecture_Produts_OLTP.0 - Finished processing [I=500, O=0, R=0, W=

2025-11-21 11:22:58.121 - Renommer_Colonne.0 - Finished processing [I=0, O=0, R=500, W=5

2025-11-21 11:22:58.274 - Ecriture_DimProduit.0 - Finished processing [I=0, O=500, R=500, W=

2025-11-21 11:22:58.276 - Spoon - The transformation has finished!!

Spoon - dim_date (changed)

File Edit View Action Tools Help

View Design

generate :

Input

Generate random credit card numbers

Generate random value

Generate rows

Output

Streaming

Transform

Utility

Flow

Scripting

Pentaho Server

Lookup

Joins

Data Warehouse

Validation

Statistics

Big Data

Cryptography

Job

Mapping

Bulk loading

Inline

Experimental

Legacy

Deprecated

History

Generate rows

Step name: **Generer_Lignes**

Limit: **1096**

Never stop generating rows: ☐

Interval in ms (delay): **3000**

Current row time field name: **now**

Previous row time field name: **FiveSecondsAgo**

Fields:

#	Name	Type	Format	Length	Precision	Currency	Decimal	Group	Value	Set empty string?
1	compteur	Integer							0	

OK Preview Cancel

Résultat attendu : La table DimProduit contient 500 lignes

Étape 4 : Transformation 3 - Générer DimDate

La dimension date est particulière : elle n'existe pas dans l'OLTP. Nous allons la générer artificiellement pour couvrir la période 2022-2024.

4.2 - Créer une nouvelle transformation

Créez une nouvelle transformation et sauvegardez-la : **dim_date.ktr**

4.3 - Ajouter un step "Add sequence"

- Dans le panneau de gauche, sous **Transform**, trouvez **Add sequence**

4. Configuration :

- Step name : **Generer_Lignes**
- Limit : **1096** (nombre de jours entre 2022-01-01 et 2024-12-31)
- Dans la section **Fields**, ajoutez un champ :
 - Name : **compteur**
 - Type : **Integer**
 - Value : **0**

5. Cliquez sur **OK**

Spoon - dim_date (changed)

View Design Action Tools Help

Search

Transform

- Add IAM
- Add a checksum
- Add constants
- Add sequence
- Add value fields changing sequence
- Calculator
- Closure generator
- Concat fields
- Get ID from slave server
- Number range
- Replace in string
- Row denormaliser
- Row flattener
- Row normaliser
- Select values
- Set field value
- Set field value to a constant
- Sort rows
- Split field to rows
- Split fields
- String operations
- Strings cut
- Unique rows
- Unique rows (HashSet)
- Value mapper
- XSL transformation

Utility

Flow

Scripting

Pentaho Server

Lookup

Joins

Data Warehouse

Generer_Lignes

Ajouter_Sequence

Add sequence

Step name: Ajouter_Sequence

Name of value: numero_jour

Use a database to generate the sequence?

Use DB to get sequence? ☐

Connection: Edit... New... Wizard...

Schema name: Schemas...

Sequence name: SEQ Sequences...

Use a transformation counter to generate the sequence?

Use counter to calculate sequence? ☒

Counter name (optional):

Start at value: 0

Increment by: 1

Maximum value: 999999999

Help OK Cancel

TP: Pipeline OLP - ETL Pent...

File D:\Eids\6204\Data_Warehouse\o2.html

3. Double-cliquez dessus

4. Configuration :

- Step name : Generer_Lignes
- Limit : 1096 (nombre de jours entre 2022-01-01 et 2024-12-31)
- Dans la section **Fields**, ajoutez un champ :
 - Name : compteur
 - Type : Integer
 - Value : 0

5. Cliquez sur **OK**

4.3 - Ajouter un step "Add sequence"

- Dans le panneau de gauche, sous **Transform**, trouvez **Add sequence**
- Glissez-déposez et créez le lien depuis "Generer_Lignes"
- Double-cliquez dessus
- Configuration :
 - Step name : Ajouter_Sequence
 - Value name : numero_jour
 - Start value : 0
 - Increment : 1
- Cliquez sur **OK**

4.4 - Ajouter un step "Calculator"

- Trouvez **Calculator** sous **Transform**
- Glissez-déposez et créez le lien
- Double-cliquez dessus
- Configuration :

Spoon - dim_date

Modified JavaScript value

View Design Action Tools Help

JavaScript functions:

- Transform Scripts
- Transform Constants
- Transform Functions
- Input fields
- Output fields
- Stream
- Transform
- Utility
- Flow
- Script
- Pentaho
- Lookup
- Joins
- Data Warehouse
- Validat
- Statist
- Big Dat
- Crypto
- Job
- Mapping
- Bulk lo
- Inline
- Export
- Legacy
- Digres
- Map

JavaScript:

```
// Créer la date de base (1er janvier 2022)
var date_base = new Date(2022, 0, 1);

// Ajouter le nombre de jours
date_base.setDate(date_base.getDate() + numero_jour);

// Créer la date complète
var date_complete = date_base;

// Extraire les composantes
var annee = date_base.getFullYear();
var mois = date_base.getMonth() + 1;
var jour = date_base.getDate();
var trimestre = Math.ceil(mois / 3);
var jour_semaine = date_base.getDay() == 0 ? 7 : date_base.getDay();

// Calculer id_date_dim (format YYYYMMDD)
var id_date_dim = annee * 10000 + mois * 100 + jour;

// Noms des mois
var noms_mois = ['Janvier', 'Février', 'Mars', 'Avril', 'Mai', 'Juin', 'Juillet', 'Août', 'Septembre', 'Octobre', 'Novembre', 'Décembre'];
var nom_mois = noms_mois[mois - 1];

// Noms des jours
var noms_jours = ['Lundi', 'Mardi', 'Mercredi', 'Jeudi', 'Vendredi', 'Samedi', 'Dimanche'];
var nom_jour = noms_jours[jour_semaine - 1];
```

Fields

#	Fieldname	Rename to	Type	Length	Precision	Replace value 'Fieldname' or 'Rename to'
1	date_base		Date			N
2	date_complete		Date			N
3	annee		Number	16	2	N
4	mois		Number	16	2	N
5	jour		Number	16	2	N
6	trimestre		Number	16	2	N
7	jour_semaine		Number	16	2	N
8	id_date_dim		Number	16	2	N
9	noms_mois		String			N

TP: Pipeline OLP - ETL Pent...

File D:\Eids\6204\Data_Warehouse\o2.html

Note : Si le Calculator ne propose pas l'option "Add days to a date", utilisez plutôt un **Modified Java Script Value** (voir ci-dessous).

4.5 - Alternative : Utiliser "Modified Java Script Value"

Si le Calculator ne fonctionne pas, utilisez cette méthode :

- Trouvez **Modified Java Script Value** sous **Scripting**
- Remplacez le Calculator par ce step
- Double-cliquez dessus
- Dans le champ de script, collez :

```
// Créer la date de base (1er janvier 2022)
var date_base = new Date(2022, 0, 1);

// Ajouter le nombre de jours
date_base.setDate(date_base.getDate() + numero_jour);

// Créer la date complète
var date_complete = date_base;

// Extraire les composantes
var annee = date_base.getFullYear();
var mois = date_base.getMonth() + 1;
var jour = date_base.getDate();
var trimestre = Math.ceil(mois / 3);
var jour_semaine = date_base.getDay() == 0 ? 7 : date_base.getDay();

// Calculer id_date_dim (format YYYYMMDD)
var id_date_dim = annee * 10000 + mois * 100 + jour;

// Noms des mois
var noms_mois = ['Janvier', 'Février', 'Mars', 'Avril', 'Mai', 'Juin', 'Juillet', 'Août', 'Septembre', 'Octobre', 'Novembre', 'Décembre'];
var nom_mois = noms_mois[mois - 1];

// Noms des jours
```

Spooon - dim_date (changed)

File Edit View Action Tools Help

View Design

Connect

select

Input
Output
Streaming
Transform
Utility
Flow
Scripting
Pentaho Server
Lookup
Joins
Data Warehouse
Validation
Statistics
Big Data
Cryptography
Job
Mapping
Bulk loading
Inline
Experimental
Legacy
Deprecated
History
Select values

dim_produit

Transformation 1

Genre_Lignes

Ajouter_Sequences

Select values

Modified JavaScript value

Select values

Step name Select values

Select & Alter Remove (Meta-data)

#	Fieldname	Rename to	Length	Precision
1	id_date_dim			
2	date_complete			
3	annee			
4	trimestre			
5	mois			
6	nom_mois			
7	jour			
8	jour_semaine			
9	nom_jour			
10				

Get fields to select
Edit Mapping

Include unspecified fields, ordered by name ☐

Help OK Cancel

TP : Pipeline OLP - ETL Pentaho

D:\Edu\204\Data_Warehouse\ol2.html

YouTube Maps Gmail Tampermonkey Log in Watch History More...

Clicker sur **Get variables** pour déclarer automatiquement les variables de sortie

Clicker sur **OK**

4.6 - Ajouter un step "Select values"

1. Ajoutez **Select values**

2. Sélectionnez uniquement les champs nécessaires dans cet ordre :

- id_date_dim
- date_complete
- annee
- trimestre
- mois
- nom_mois
- jour
- jour_semaine
- nom_jour

4.7 - Ajouter un step "Table Output"

1. Ajoutez **Table output**

2. Configuration :

- Step name : Ecriture_DimDate
- Connection : DWH_MySQL
- Target table : DimDate
- Cocher **Truncate table**

4.8 - Exécuter la transformation

Spooon - dim_date

File Edit View Action Tools Help

View Design

Connect

Search

Input
Output
Streaming
Transform
Utility
Flow
Scripting
Pentaho Server
Lookup
Joins
Data Warehouse
Validation
Statistics
Big Data
Cryptography
Job
Mapping
Bulk loading
Inline
Experimental
Legacy
Deprecated
History

dim_produit

dim_date

Genre_Lignes

Ajouter_Sequences

Ecriture_DimDate

Select values

Modified JavaScript value

Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data

2025-11-22 14:01:52.848 - Spoon - Transformation opened.

2025-11-22 14:01:52.848 - Spoon - Launching transformation [dim_date]...

2025-11-22 14:01:52.848 - Spoon - Started the transformation execution.

2025-11-22 14:01:52.870 - dim_date - Dispatching started for transformation [dim_date]

2025-11-22 14:01:52.874 - Ecriture_DimDate - Connected to database [DWH_MySQL] (commit=1000)

2025-11-22 14:01:52.878 - Modified JavaScript value - Optimization level set to 5

2025-11-22 14:01:52.878 - Genre_Lignes - Finished processing [r=0, O=0, R=0, W=1096, U=0, E=0]

2025-11-22 14:01:52.892 - Ajouter_Sequences - Finished processing [r=0, O=0, R=1096, W=1096, U=0, E=0]

2025-11-22 14:01:52.891 - Modified JavaScript value - Finished processing [r=0, O=0, R=1096, W=1096, U=0, E=0]

2025-11-22 14:01:53.001 - Select values - Finished processing [r=0, O=0, R=1096, W=1096, U=0, E=0]

2025-11-22 14:01:53.218 - Ecriture_DimDate - Finished processing [r=0, O=0, R=1096, W=1096, U=0, E=0]

2025-11-22 14:01:53.219 - Spoon - The transformation has finished!

TP : Pipeline OLP - ETL Pentaho

D:\Edu\204\Data_Warehouse\ol2.html

YouTube Maps Gmail Tampermonkey Log in Watch History More...

- annee
- trimestre
- mois
- nom_mois
- jour
- jour_semaine
- nom_jour

4.7 - Ajouter un step "Table Output"

1. Ajoutez **Table output**

2. Configuration :

- Step name : Ecriture_DimDate
- Connection : DWH_MySQL
- Target table : DimDate
- Cocher **Truncate table**

4.8 - Exécuter la transformation

Clicker sur **Run** et vérifiez que 1096 dates sont générées

Résultat attendu : La table DimDate contient 1096 lignes couvrant la période 2022-2024. Vérifiez avec :

```
SELECT * FROM ventes_dwh.DimDate ORDER BY date_complete LIMIT 10;
```

Étape 5 : Transformation 4 - Charger FactVentes (la plus complexe)

Cette transformation est la plus importante car elle crée la table de faits en effectuant des jointures entre les données OLP et les dimensions du DWH.

amamouTp x

Edit View Query Database Server Tools Scripting Help

SQLAdditions

Jump to

Limit to 1000 rows

1 • use ventes_dwh;
2 • SELECT COUNT(*) FROM ventes_dwh.DimClient;
3 • SELECT * FROM ventes_dwh.DimDate ORDER BY date_complete LIMIT 10;

Result Grid

id_date_dim	date_complete	annee	trimestre	mois	nom_mois	jour	jour_semaine	nom_jour
20220103	2022-01-03	2022	1	1	Janvier	3	1	Lundi
20220104	2022-01-04	2022	1	1	Janvier	4	2	Mardi
20220105	2022-01-05	2022	1	1	Janvier	5	3	Mercredi
20220106	2022-01-06	2022	1	1	Janvier	6	4	Jeudi
20220107	2022-01-07	2022	1	1	Janvier	7	5	Vendredi
20220108	2022-01-08	2022	1	1	Janvier	8	6	Samedi
20220109	2022-01-09	2022	1	1	Janvier	9	7	Dimanche
20220110	2022-01-10	2022	1	1	Janvier	10	1	Lundi
NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL

Result 1 DimDate 2 x

Apply Revert Context Help Snippets

Output

Action Output

#	Time	Action	Message	Duration / Fetch
✓ 1	14:02:18	use ventes_dwh	0 row(s) affected	0.000 sec
✓ 2	14:02:22	use ventes_dwh	0 row(s) affected	0.000 sec
✓ 3	14:02:22	SELECT COUNT(*) FROM ventes_dwh.DimClient LIMIT 0, 1000	1 row(s) returned	0.000 sec / 0.000 sec
✓ 4	14:02:22	SELECT * FROM ventes_dwh.DimDate ORDER BY date_compl...	10 row(s) returned	0.000 sec / 0.000 sec

Automatic context help is disabled. Use the toolbar manually get help for the current caret position or to toggle automatic help.

No object selected

Spoon - fact_ventes

le Edit View Action Tools Help

table

Input

Get table names

Table input

Output

Delete

Table output

Update

Streaming

Transform

Closure generator

Utility

Table compare

Flow

Scripting

Pentaho Server

Lookup

Table exists

Joins

Data Warehouse

Validation

Statistics

Big Data

Cryptography

Job

Mapping

Bulk loading

Inline

Experimental

Legacy

Deprecated

History

Table input

Welcome!

job_etl_complet

fact_ventes

100%

Table input

Lookup_Client

Lookup_Produit

Lookup_Date

Calculer_Montant

Select values

Ecriture_FactVentes

Execution Results

Logging

Execution History

Step Metrics

Performance Graph

Metrics

Preview data

2025-11-22 14:20:12.462 - Table input.0 - linenr 100000

2025-11-22 14:20:12.462 - Table input.0 - Finished reading query, closing connection

2025-11-22 14:20:12.462 - Table input.0 - Finished processing (I=100000, O=0, R=0, W=100000, U=0, E=0)

2025-11-22 14:20:13.276 - Ecriture_FactVentes.0 - linenr 50000

2025-11-22 14:20:13.283 - Lookup_Client.0 - linenr 100000

2025-11-22 14:20:13.289 - Lookup_Client.0 - Finished processing (I=8656, O=0, R=100000, W=100000, U=0, E=0)

2025-11-22 14:20:14.148 - Lookup_Produit.0 - linenr 100000

2025-11-22 14:20:14.151 - Lookup_Produit.0 - Finished processing (I=500, O=0, R=100000, W=100000, U=0, E=0)

2025-11-22 14:20:15.008 - Lookup_Date.0 - linenr 100000

2025-11-22 14:20:15.022 - Lookup_Date.0 - Finished processing (I=1096, O=0, R=100000, W=100000, U=0, E=0)

2025-11-22 14:20:15.847 - Calculer_Montant.0 - Linenr 100000

2025-11-22 14:20:15.851 - Calculer_Montant.0 - Finished processing (I=0, O=0, R=100000, W=100000, U=0, E=0)

2025-11-22 14:20:16.659 - Select values.0 - linenr 100000

2025-11-22 14:20:16.690 - Select values.0 - Finished processing (I=0, O=0, R=100000, W=100000, U=0, E=0)

2025-11-22 14:20:17.495 - Ecriture_FactVentes.0 - linenr 100000

2025-11-22 14:20:17.519 - Ecriture_FactVentes.0 - Finished processing (I=0, O=100000, R=100000, W=100000, U=0, E=0)

2025-11-22 14:20:17.520 - Spoon - The transformation has finished!!

amamouTp x

Limit to 1000 rows

```
1 • use ventes_dwh;
2 • SELECT COUNT(*) FROM ventes_dwh.DimClient;
3 • SELECT * FROM ventes_dwh.DimDate ORDER BY date_complete LIMIT 10;
4 • SELECT COUNT(*) FROM ventes_dwh.FactVentes;
```

Result Grid

	COUNT(*)
▶	100000

Export: Wrap Cell Content:

Result Grid

The screenshot shows the SAP Data Warehouse Cloud (DWC) interface. The top pane displays a job design with a 'Start' node connected to four dimension tables: 'Charger_DimClient', 'Charger_DimProduit', 'Charger_DimDate', and 'Charger_FactVentes'. These are all connected to a 'Message_Succes' target. The 'Charger_DimClient' and 'Charger_DimProduit' nodes show red error icons. The bottom pane shows the 'Execution Results' log, which contains a list of successful processing steps followed by a final error message: 'ETL Complet - Toutes les transformations ont été exécutées avec succès ! Le Data Warehouse e'.

The error is occurred when I close a transformation, I lose all the database connection I had configured last time and I'm sure if I reopen and reconfigure those datasets it will work perfectly.

Chiffre d'affaires par ville :

	ville	chiffre_affaires	nombre_clients	nombre_ventes
►	Montpellier	133901589479.19	748	9203
	Rennes	132067198845.21	782	8855
	Bordeaux	128959772741.71	732	8530
	Nice	124825329870.84	729	8523
	Marseille	123231633834.34	729	8379
	Strasbourg	123006595866.35	711	8355
	Nantes	120333190070.09	718	8094
	Lille	119374069839.74	729	8398
	Lyon	118880212776.15	713	8227
	Reims	118605679679.47	733	8182
	Toulouse	113523133817.79	676	7711
	Paris	113078968042.76	656	7543

Chiffre d'affaires par catégorie de produit :

	categorie	chiffre_affaires	quantite_vendue	nombre_produits_distincts	prix_moyen
►	Ordinateurs	331862785961.87	60514	100	1070.22
	Téléphones	322965123092.48	60122	100	1072.42
	Accessoires	291740167650.50	60127	100	1000.07
	Tablettes	270319800683.39	59296	100	953.92
	Montres	252899497475.40	59737	100	919.41

Évolution des ventes par mois :

	annee	mois	nom_mois	chiffre_affaires	nombre_ventes	panier_moyen
►	2022	1	Janvier	43287700485.99	3003	14414818.68
	2022	2	Février	39795150841.05	2655	14988757.38
	2022	3	Mars	41512981701.98	2892	14354419.68
	2022	4	Avril	40935280010.38	2767	14794101.92
	2022	5	Mai	38134634138.54	2705	14097831.47
	2022	6	Juin	38988529528.84	2602	14984062.08
	2022	7	Juillet	40696007623.15	2887	14096296.37
	2022	8	Août	41579003698.56	2740	15174818.87
	2022	9	Septembre	40337505755.34	2717	14846339.99
	2022	10	Octobre	38605837863.09	2688	14362290.87
	2022	11	Novembre	40846240930.98	2760	14799362.66
	2022	12	Décembre	40426569706.64	2770	14594429.50
	2023	1	Janvier	40379679193.66	2647	15254884.47
	2023	2	Février	34080358383.75	2381	14317744.18

Top 10 des produits les plus vendus :

	nom_produit	categorie	quantite_totale_vendue	chiffre_affaires	prix_moyen
►	Apple Watch Plus	Montres	751	9008037578.61	1776.81
	Clavier mécanique Ultra	Accessoires	740	8319652358.56	1726.43
	Huawei MatePad Lite	Tablettes	734	96784177.44	186.37
	Xiaomi 13 Plus	Téléphones	725	5578267755.06	1442.98
	HP Pavilion Plus	Ordinateurs	714	711815045.76	518.16
	iPhone 14 Standard	Téléphones	707	8394043398.77	1782.59
	Asus VivoBook Ultra	Ordinateurs	704	8378589093.12	1797.82
	Garmin Forerunner Lite	Montres	704	3268228271.04	1097.54
	Webcam HD Ultra	Accessoires	703	6492772694.10	1594.23
	OnePlus 11 Standard	Téléphones	702	3471490724.52	1167.47

Analyse par trimestre et catégorie (analyse croisée) :

	annee	trimestre	categorie	chiffre_affaires	quantite_vendue
▶	2022	1	Ordinateurs	27675137168.84	5081
	2022	1	Téléphones	27562622773.31	5004
	2022	1	Accessoires	25048632696.22	5135
	2022	1	Tablettes	23336737649.35	5287
	2022	1	Montres	20972702741.30	5208
	2022	2	Ordinateurs	28707760981.82	5183
	2022	2	Téléphones	27456416146.89	5091
	2022	2	Accessoires	22163505634.88	4617
	2022	2	Tablettes	21220035360.80	4516
	2022	2	Montres	18510725553.37	4664
	2022	3	Téléphones	28444448063.09	5146
	2022	3	Ordinateurs	28045394051.74	5164
	2022	3	Accessoires	24439167356.56	5014
	2022	3	Tablettes	23110600005.70	4061

Now we will move to the next stuff which is the use of BI to make readable graphs.

The screenshot shows the Power BI Desktop interface with a data model. The model consists of four tables: **ventes_dwh dimclient**, **ventes_dwh dimdate**, **ventes_dwh dimproduit**, and **ventes_dwh factventes**. The factventes table is connected to the three dimension tables. The web browser on the right displays a tutorial for importing data from a Data Warehouse.

Étape 2 - Importer les tables du Data Warehouse

2.1 - Sélectionner les tables

- Dans la fenêtre Navigateur qui s'affiche, vous voyez la liste des tables de ventes_dwh
- Cochez les 4 tables :
 - ☒ DimClient
 - ☒ DimProduit
 - ☒ DimDate
 - ☒ FactVent
- Cliquez sur **Charger** (Load)

2.2 - Attendre le chargement

Power BI importe les données. Cela peut prendre 30 secondes à 1 minute pour les 100 000 lignes de FactVent.


Résultat attendu : Dans le panneau de droite "Champs" (Fields), vous voyez maintenant les 4 tables avec leurs colonnes respectives.

Étape 3 : Vérifier et configurer le modèle de données

3.1 - Ouvrir la vue Modèle

- Sur le côté gauche, cliquez sur l'icône **Modèle** (trois tables reliées)
- Vous voyez un diagramme avec les 4 tables


3.2 - Vérifier les relations automatiques



1. There is an error in the tp the

Glissez **DimProduit.nom_produit** vers **Axe Y**

Should be used in Axe X not Y!!!!!!!!!!!!!!



We can see that reading graphs using BI is faster and easier then the normal graphs.

The screenshot shows the Power BI Desktop interface. On the left, the DAX editor contains the following code:

```
1 EVALUATE
2 SUMMARIZECOLUMNS(
3     "CA Total", [CA Total]
4 )
```

The results pane shows a single row with the value 1469787374863.64. On the right, the 'Modèle' sidebar is visible, showing a list of measures including 'CA Total', 'Clients Uniques', 'Nombre de Ventes', and 'Panier Moyen'. To the right of the sidebar, there are two instructional panels:

6.4 - Créer une mesure "Nombre de clients uniques"

1. Nouvelle mesure :

`Clients Uniques = DISTINCTCOUNT(FactVentes[id_c])`

6.5 - Utiliser les mesures

1. Créez une **Carte** (Card) pour afficher le CA Total
2. Créez une autre carte pour le Panier Moyen
3. Créez une carte pour Nombre de Ventes
4. Créez une carte pour Clients Uniques
5. Positionnez ces 4 cartes en haut du rapport comme des KPI

In here we display the value of the CA total.

Notice for the code there is an error in the syntax don't use

CA Total = SUM(FactVentes[montant_total])

Instead use:

CA Total = SUM('ventes_dwh factventes'[montant_total])

Don't use also:

Nombre de Ventes = COUNT(FactVentes[id_vente])

Use instead :

Nombre de Ventes = COUNT('ventes_dwh factventes'[id_vente])

The screenshot shows the Power BI Desktop interface with the DAX editor updated to:

```
1 EVALUATE
2 SUMMARIZECOLUMNS(
3     "Panier Moyen", [Panier Moyen]
4 )
```

The results pane shows a single row with the value 14697873.75. On the right, the 'Modèle' sidebar is visible, showing a list of measures including 'CA Total', 'Clients Uniques', 'Nombre de Ventes', and 'Panier Moyen'. To the right of the sidebar, there are two instructional panels:


6.5 - Utiliser les mesures

1. Créez une **Carte** (Card) pour afficher le CA Total
2. Créez une autre carte pour le Panier Moyen
3. Créez une carte pour Nombre de Ventes
4. Créez une carte pour Clients Uniques
5. Positionnez ces 4 cartes en haut du rapport comme des KPI


Résultat attendu : Vous avez maintenant un tableau de bord complet avec :

- 4 cartes KPI en haut (CA Total, Panier Moyen, Nombre de Ventes, Clients Uniques)
- 2 segments interactifs (Année, Catégorie)
- 4 visualisations principales (CA par ville, CA par catégorie, Évolution mensuelle, Top 10 produits)
- Interactivité complète entre tous les visuels


♦ **Étape 7 : Mise en forme et design professionnel**



This is the final dashboard with all needed stuff to do good analysis and report to the end user.



If we try to modify the theme.



After realignment:



